


## 17 | 决策树（上）：要不要去打篮球？决策树来告诉你

2019-01-21 陈旻



讲述：陈旻

时长 17:30 大小 16.04M



想象一下一个女孩的妈妈给她介绍男朋友的场景：

女儿：长的帅不帅？

妈妈：挺帅的。

女儿：有没有房子？

妈妈：在老家有一个。

女儿：收入高不高？

妈妈：还不错，年薪百万。

女儿：做什么工作的？

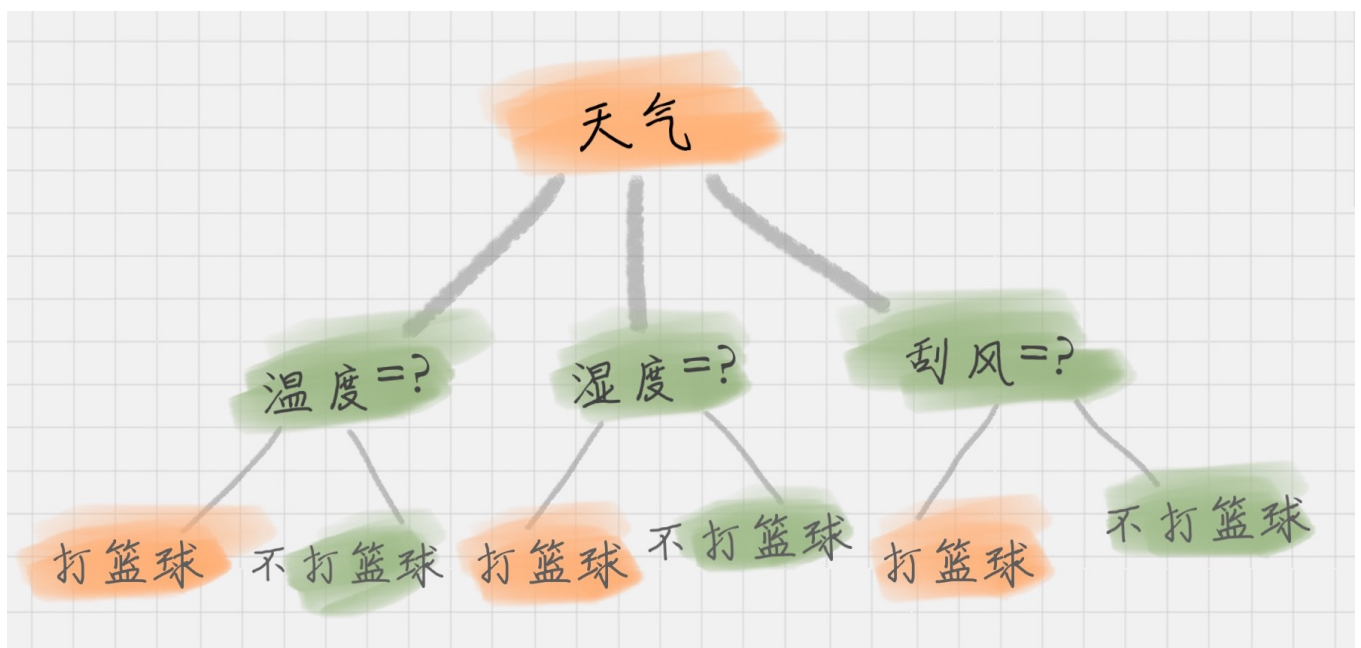
妈妈：IT 男，互联网公司做数据挖掘的。

女儿：好，那我见见。

在现实生活中，我们会遇到各种选择，不论是选择男女朋友，还是挑选水果，都是基于以往的经验来做判断。如果把判断背后的逻辑整理成一个结构图，你会发现它实际上是一个树状图，这就是我们今天要讲的**决策树**。

## 决策树的工作原理

决策树基本上就是把我们的经验总结出来。我给你准备了一个打篮球的训练集。如果我们要出门打篮球，一般会根据“天气”、“温度”、“湿度”、“刮风”这几个条件来判断，最后得到结果：去打篮球？还是不去？



上面这个图就是一棵典型的决策树。我们在做决策树的时候，会经历两个阶段：**构造和剪枝**。

### 构造

什么是构造呢？构造就是生成一棵完整的决策树。简单来说，**构造的过程就是选择什么属性作为节点的过程**，那么在构造过程中，会存在三种节点：

1. 根节点：就是树的最顶端，最开始的那个节点。在上图中，“天气”就是一个根节点；
2. 内部节点：就是树中间的那些节点，比如说“温度”、“湿度”、“刮风”；
3. 叶节点：就是树最底部的节点，也就是决策结果。

节点之间存在父子关系。比如根节点会有子节点，子节点会有子子节点，但是到了叶节点就停止了，叶节点不存在子节点。那么在构造过程中，你要解决三个重要的问题：


1. 选择哪个属性作为根节点；
2. 选择哪些属性作为子节点；
3. 什么时候停止并得到目标状态，即叶节点。

## 剪枝

决策树构造出来之后是不是就万事大吉了呢？也不尽然，我们可能还需要对决策树进行剪枝。剪枝就是给决策树瘦身，这一步想实现的目标就是，不需要太多的判断，同样可以得到不错的结果。之所以这么做，是为了防止“过拟合”（Overfitting）现象的发生。

“过拟合”这个概念你一定要理解，它指的就是模型的训练结果“太好了”，以至于在实际应用的过程中，会存在“死板”的情况，导致分类错误。

欠拟合，和过拟合就好比是下面这张图中的第一个和第三个情况一样，训练的结果“太好”，反而在实际应用过程中会导致分类错误。



造成过拟合的原因之一就是因为训练集中样本量较小。如果决策树选择的属性过多，构造出来的决策树一定能够“完美”地把训练集中的样本分类，但是这样就会把训练集中一些数据的特点当成所有数据的特点，但这个特点不一定是全部数据的特点，这就使得这个决策树在真实的数据分类中出现错误，也就是模型的“泛化能力”差。

泛化能力指分类器是通过训练集抽象出来的分类能力，你也可以理解是举一反三的能力。如果我们太依赖于训练集的数据，那么得到的决策树容错率就会比较低，泛化能力差。因为训练集只是全部数据的抽样，并不能体现全部数据的特点。

既然要对决策树进行剪枝，具体有哪些方法呢？一般来说，剪枝可以分为“预剪枝”（Pre-Pruning）和“后剪枝”（Post-Pruning）。

预剪枝是在决策树构造时就进行剪枝。方法是在构造的过程中对节点进行评估，如果对某个节点进行划分，在验证集中不能带来准确性的提升，那么对这个节点进行划分就没有意义，这时就会把当前节点作为叶节点，不对其进行划分。

后剪枝就是在生成决策树之后再进行剪枝，通常会从决策树的叶节点开始，逐层向上对每个节点进行评估。如果剪掉这个节点子树，与保留该节点子树在分类准确性上差别不大，或者剪掉该节点子树，能在验证集中带来准确性的提升，那么就可以把该节点子树进行剪枝。方法是：用这个节点子树的叶子节点来替代该节点，类标记为这个节点子树中最频繁的那个类。

## 如何判断要不要去打篮球？

我给你准备了打篮球的数据集，训练数据如下：

天气	温度	湿度	刮风	是否打篮球
晴天	高	中	否	否
晴天	高	中	是	否
阴天	高	高	否	是
小雨	高	高	否	是
小雨	低	高	否	否
晴天	中	中	是	是
阴天	中	高	是	否

我们该如何构造一个判断是否去打篮球的决策树呢？再回顾一下决策树的构造原理，在决策过程中有三个重要的问题：将哪个属性作为根节点？选择哪些属性作为后继节点？什么时候停止并得到目标值？



显然将哪个属性（天气、温度、湿度、刮风）作为根节点是个关键问题，在这里我们先介绍两个指标：**纯度**和**信息熵**。

先来说一下纯度。你可以把决策树的构造过程理解成为寻找纯净划分的过程。数学上，我们可以用纯度来表示，纯度换一种方式来解释就是让目标变量的分歧最小。

我在这里举个例子，假设有 3 个集合：

- 集合 1：6 次都去打篮球；
- 集合 2：4 次去打篮球，2 次不去打篮球；
- 集合 3：3 次去打篮球，3 次不去打篮球。

按照纯度指标来说，集合 1> 集合 2> 集合 3。因为集合 1 的分歧最小，集合 3 的分歧最大。

然后我们再来介绍信息熵（entropy）的概念，**它表示了信息的不确定度**。

在信息论中，随机离散事件出现的概率存在着不确定性。为了衡量这种信息的不确定性，信息学之父香农引入了信息熵的概念，并给出了计算信息熵的数学公式：

$$Entropy(t) = - \sum_{i=0}^{c-1} p(i | t) \log_2 p(i | t)$$

$p(i|t)$  代表了节点  $t$  为分类  $i$  的概率，其中  $\log_2$  为取以 2 为底的对数。这里我们不是来介绍公式的，而是说存在一种度量，它能帮我们反映出来这个信息的不确定度。当不确定性越大时，它所包含的信息量也就越大，信息熵也就越高。

我举个简单的例子，假设有 2 个集合

- 集合 1：5 次去打篮球，1 次不去打篮球；
- 集合 2：3 次去打篮球，3 次不去打篮球。

在集合 1 中，有 6 次决策，其中打篮球是 5 次，不打篮球是 1 次。那么假设：类别 1 为“打篮球”，即次数为 5；类别 2 为“不打篮球”，即次数为 1。那么节点划分为类别 1 的概率是 5/6，为类别 2 的概率是 1/6，带入上述信息熵公式可以计算得出：

$$Entropy(t) = -(1/6)\log_2(1/6) - (5/6)\log_2(5/6) = 0.65$$

同样，集合 2 中，也是一共 6 次决策，其中类别 1 中“打篮球”的次数是 3，类别 2 “不打篮球”的次数也是 3，那么信息熵为多少呢？我们可以计算得出：

$$Entropy(t) = -(3/6)\log_2(3/6) - (3/6)\log_2(3/6) = 1$$

从上面的计算结果中可以看出，信息熵越大，纯度越低。当集合中的所有样本均匀混合时，信息熵最大，纯度最低。

我们在构造决策树的时候，会基于纯度来构建。而经典的“不纯度”的指标有三种，分别是信息增益（ID3 算法）、信息增益率（C4.5 算法）以及基尼指数（Cart 算法）。

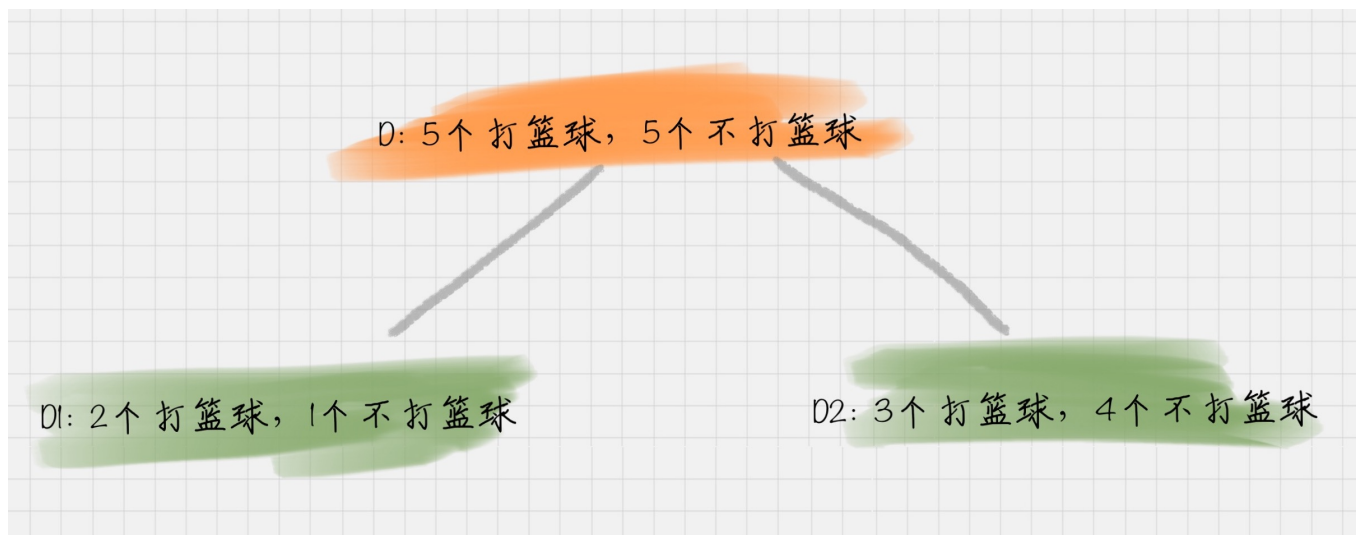
我们先看下 ID3 算法。ID3 算法计算的是**信息增益**，信息增益指的就是划分可以带来纯度的提高，信息熵的下降。它的计算公式，是父亲节点的信息熵减去所有子节点的信息熵。在计算的过程中，我们会计算每个子节点的归一化信息熵，即按照每个子节点在父节点中出现的概率，来计算这些子节点的信息熵。所以信息增益的公式可以表示为：

$$Gain(D, a) = Entropy(D) - \sum_{i=1}^k \frac{|D_i|}{|D|} Entropy(D_i)$$

公式中 D 是父亲节点，Di 是子节点，Gain(D,a) 中的 a 作为 D 节点的属性选择。

假设天气 = 晴的时候，会有 5 次去打篮球，5 次不打篮球。其中 D1 刮风 = 是，有 2 次打篮球，1 次不打篮球。D2 刮风 = 否，有 3 次打篮球，4 次不打篮球。那么 a 代表节点的属性，即天气 = 晴。

你可以在下面的图例中直观地了解这几个概念。



比如针对图上这个例子，D 作为节点的信息增益为：

$$Gain(D, a) = Entropy(D) - \left( \frac{3}{10} Entropy(D_1) + \frac{7}{10} Entropy(D_2) \right)$$

也就是 D 节点的信息熵 - 2 个子节点的归一化信息熵。2 个子节点归一化信息熵 = 3/10 的 D1 信息熵 + 7/10 的 D2 信息熵。

我们基于 ID3 的算法规则，完整地计算下我们的训练集，训练集中一共有 7 条数据，3 个打篮球，4 个不打篮球，所以根节点的信息熵是：

$$Ent(D) = - \sum_{k=1}^2 p_k \log_2 p_k = - \left( \frac{3}{7} \log_2 \frac{3}{7} + \frac{4}{7} \log_2 \frac{4}{7} \right) = 0.985$$

如果你将天气作为属性的划分，会有三个叶子节点 D1、D2 和 D3，分别对应的是晴天、阴天和小雨。我们用 + 代表去打篮球，- 代表不去打篮球。那么第一条记录，晴天不去打篮球，可以记为 1-，于是我们可以用下面的方式来记录 D1，D2，D3：

D1(天气 = 晴天) = {1-, 2-, 6+}

D2(天气 = 阴天) = {3+, 7-}

D3(天气 = 小雨) = {4+, 5-}

我们先分别计算三个叶子节点的信息熵：

$$\text{Ent}(D_1) = -\left(\frac{1}{3}\log_2\frac{1}{3} + \frac{2}{3}\log_2\frac{2}{3}\right) = 0.918$$

$$\text{Ent}(D_2) = -\left(\frac{1}{2}\log_2\frac{1}{2} + \frac{1}{2}\log_2\frac{1}{2}\right) = 1.0$$

$$\text{Ent}(D_3) = -\left(\frac{1}{2}\log_2\frac{1}{2} + \frac{1}{2}\log_2\frac{1}{2}\right) = 1.0$$

因为 D1 有 3 个记录，D2 有 2 个记录，D3 有 2 个记录，所以 D 中的记录一共是 3+2+2=7，即总数为 7。所以 D1 在 D（父节点）中的概率是 3/7，D2 在父节点的概率是 2/7，D3 在父节点的概率是 2/7。那么作为子节点的归一化信息熵 = 3/7\*0.918+2/7\*1.0+2/7\*1.0=0.965。

因为我们用 ID3 中的信息增益来构造决策树，所以要计算每个节点的信息增益。

天气作为属性节点的信息增益为，Gain(D, 天气)=0.985-0.965=0.020。。

同理我们可以计算出其他属性作为根节点的信息增益，它们分别为：

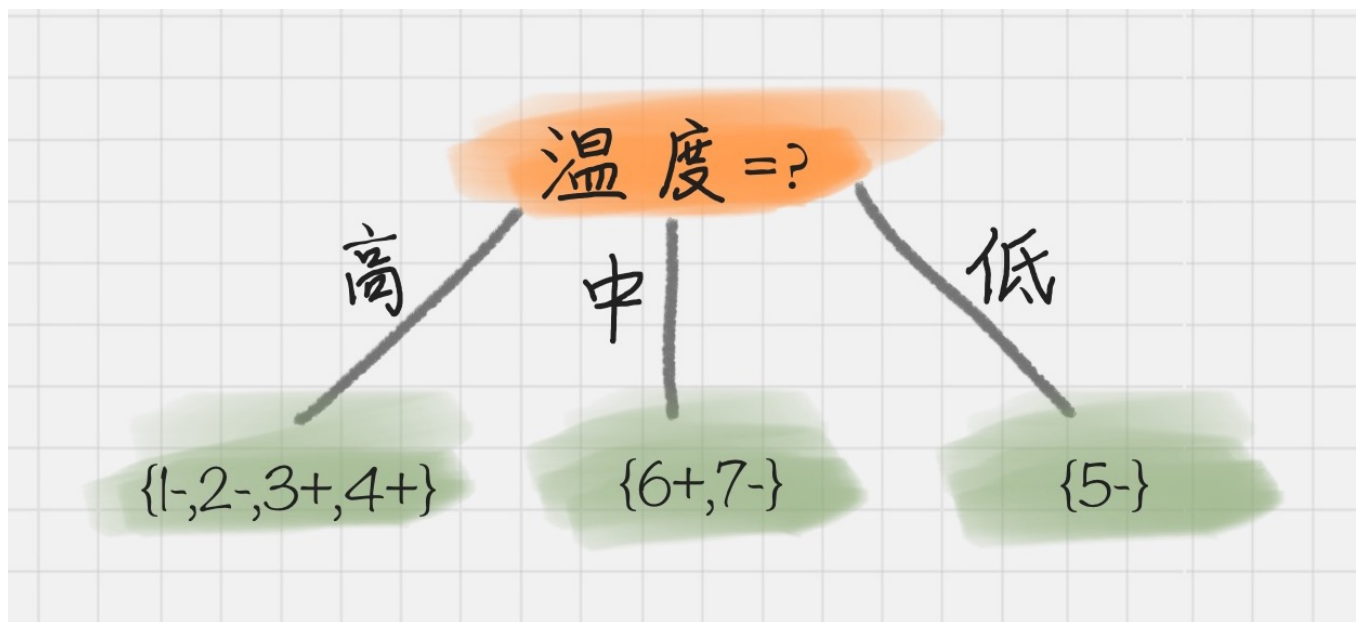
$$\text{Gain}(D, \text{温度})=0.128$$

$$\text{Gain}(D, \text{湿度})=0.020$$

$$\text{Gain}(D, \text{刮风})=0.020$$

我们能看出来温度作为属性的信息增益最大。因为 ID3 就是要将信息增益最大的节点作为父节点，这样可以得到纯度高的决策树，所以我们将温度作为根节点。其决策树状图分裂为下图所示：





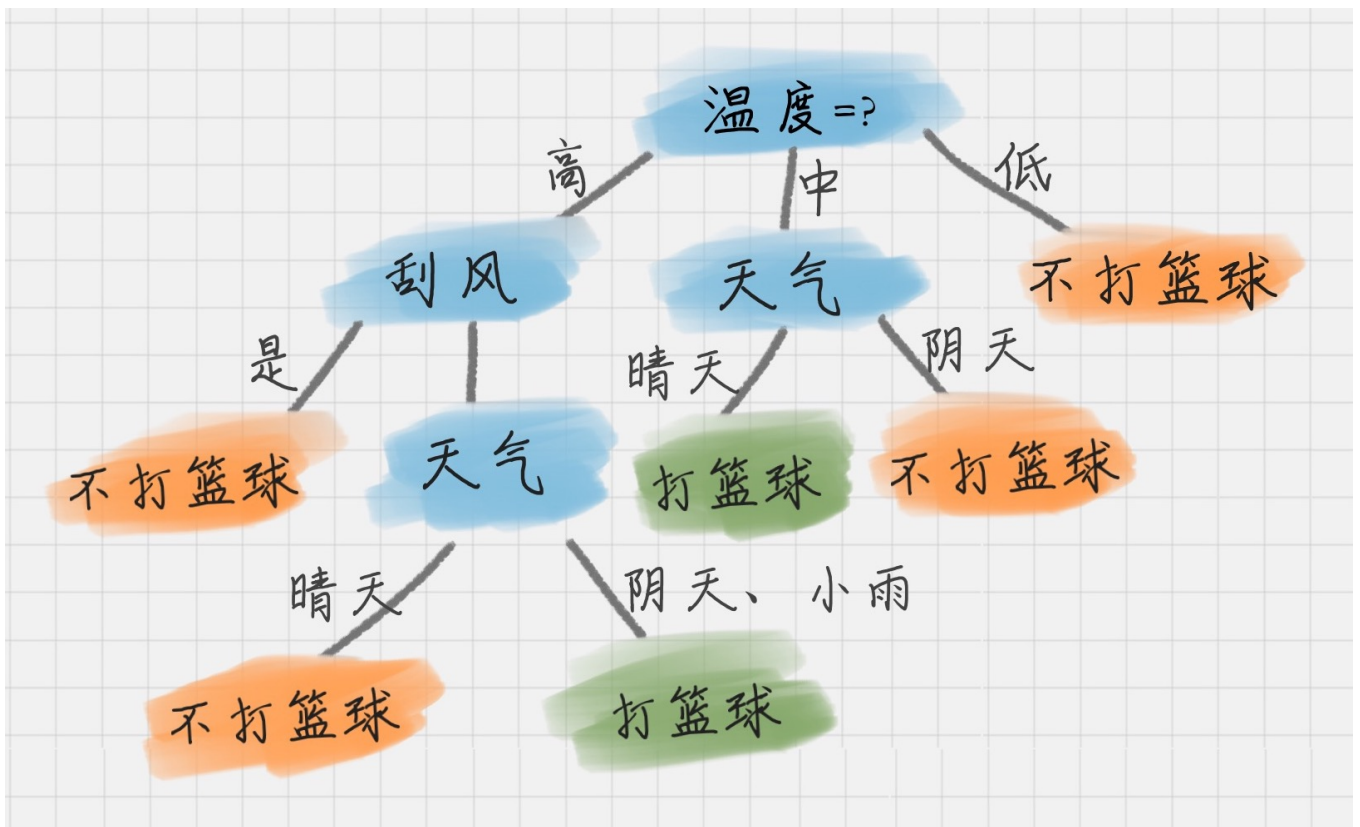
然后我们要将上图中第一个叶节点，也就是  $D1=\{1-, 2-, 3+, 4+\}$  进一步进行分裂，往下划分，计算其不同属性（天气、湿度、刮风）作为节点的信息增益，可以得到：

$$\text{Gain}(D, \text{天气})=0$$

$$\text{Gain}(D, \text{湿度})=0$$

$$\text{Gain}(D, \text{刮风})=0.0615$$

我们能看到刮风为  $D1$  的节点都可以得到最大的信息增益，这里我们选取刮风作为节点。同理，我们可以按照上面的计算步骤得到完整的决策树，结果如下：



于是我们通过 ID3 算法得到了一棵决策树。ID3 的算法规则相对简单，可解释性强。同样也存在缺陷，比如我们会发现 ID3 算法倾向于选择取值比较多的属性。这样，如果我们把“编号”作为一个属性（一般情况下不会这么做，这里只是举个例子），那么“编号”将会被选为最优属性。但实际上“编号”是无关属性的，它对“打篮球”的分类并没有太大作用。

所以 ID3 有一个缺陷就是，有些属性可能对分类任务没有太大作用，但是他们仍然可能会被选为最优属性。这种缺陷不是每次都会发生，只是存在一定的概率。在大部分情况下，ID3 都能生成不错的决策树分类。针对可能发生的缺陷，后人提出了新的算法进行改进。

## 在 ID3 算法上进行改进的 C4.5 算法

那么 C4.5 都在哪些方面改进了 ID3 呢？

### 1. 采用信息增益率

因为 ID3 在计算的时候，倾向于选择取值多的属性。为了避免这个问题，C4.5 采用信息增益率的方式来选择属性。信息增益率 = 信息增益 / 属性熵，具体的计算公式这里省略。

当属性有很多值的时候，相当于被划分成了许多份，虽然信息增益变大了，但是对于 C4.5 来说，属性熵也会变大，所以整体的信息增益率并不大。

## 2. 采用悲观剪枝

ID3 构造决策树的时候，容易产生过拟合的情况。在 C4.5 中，会在决策树构造之后采用悲观剪枝（PEP），这样可以提升决策树的泛化能力。

悲观剪枝是后剪枝技术中的一种，通过递归估算每个内部节点的分类错误率，比较剪枝前后这个节点的分类错误率来决定是否对其进行剪枝。这种剪枝方法不再需要一个单独的测试数据集。

## 3. 离散化处理连续属性

C4.5 可以处理连续属性的情况，对连续的属性进行离散化的处理。比如打篮球存在的“湿度”属性，不按照“高、中”划分，而是按照湿度值进行计算，那么湿度取什么值都有可能。该怎么选择这个阈值呢，**C4.5 选择具有最高信息增益的划分所对应的阈值。**

## 4. 处理缺失值

针对数据集不完整的情况，C4.5 也可以进行处理。

假如我们得到的是如下的数据，你会发现这个数据中存在两点问题。第一个问题是，数据集中存在数值缺失的情况，如何进行属性选择？第二个问题是，假设已经做了属性划分，但是样本在这个属性上有缺失值，该如何对样本进行划分？

ID	天气	温度	湿度	刮风	是否打篮球
1	晴天	-	中	否	否
2	晴天	高	中	是	否
3	阴天	高	高	否	是
4	小雨	高	高	否	是
5	小雨	低	高	否	否
6	晴天	中	中	是	是
7	阴天	中	高	是	否

我们不考虑缺失的数值，可以得到温度  $D=\{2-,3+,4+,5-,6+,7-\}$ 。温度 = 高： $D1=\{2-,3+,4+\}$ ；温度 = 中： $D2=\{6+,7-\}$ ；温度 = 低： $D3=\{5-\}$ 。这里 + 号代表打篮球，- 号代表不打篮球。比如 ID=2 时，决策是不打篮球，我们可以记录为 2-。

所以三个叶节点的信息熵可以结算为：

$$Ent(D_1) = -(\frac{1}{3}\log_2 \frac{1}{3} + \frac{2}{3}\log_2 \frac{2}{3}) = 0.918$$

$$Ent(D_2) = -(\frac{1}{2}\log_2 \frac{1}{2} + \frac{1}{2}\log_2 \frac{1}{2}) = 1.0$$

$$Ent(D_3) = 0$$

这三个节点的归一化信息熵为  $3/6*0.918+2/6*1.0+1/6*0=0.792$ 。

针对将属性选择为温度的信息增益率为：

$$Gain(D', \text{温度}) = Ent(D') - 0.792 = 1.0 - 0.792 = 0.208$$

D'的样本个数为 6，而 D 的样本个数为 7，所以所占权重比例为 6/7，所以 Gain(D', 温度) 所占权重比例为 6/7，所以：

$$Gain(D, \text{温度}) = 6/7 * 0.208 = 0.178$$

这样即使在温度属性的数值有缺失的情况下，我们依然可以计算信息增益，并对属性进行选择。

Cart 算法在这里不做介绍，我会在下一讲给你讲解这个算法。现在我们总结下 ID3 和 C4.5 算法。首先 ID3 算法的优点是方法简单，缺点是对噪声敏感。训练数据如果有少量错误，可能会产生决策树分类错误。C4.5 在 ID3 的基础上，用信息增益率代替了信息增益，解决了噪声敏感的问题，并且可以对构造树进行剪枝、处理连续数值以及数值缺失等情况，但是由于 C4.5 需要对数据集进行多次扫描，算法效率相对较低。

## 总结

前面我们讲了两种决策树分类算法 ID3 和 C4.5，了解了它们的数学原理。你可能会问，公式这么多，在实际使用中该怎么办呢？实际上，我们可以使用一些数据挖掘工具使用它们，比如 Python 的 sklearn，或者是 Weka（一个免费的数据挖掘工作平台），它们已经

集成了这两种算法。只是我们在了解了这两种算法之后，才能更加清楚这两种算法的优缺点。

我们总结下，这次都讲到了哪些知识点呢？

首先我们采用决策树分类，需要了解它的原理，包括它的构造原理、剪枝原理。另外在信息度量上，我们需要了解信息度量中的纯度和信息熵的概念。在决策树的构造中，一个决策树包括根节点、子节点、叶子节点。在属性选择的标准上，度量方法包括了信息增益和信息增益率。在算法上，我讲解了两种算法：ID3 和 C4.5，其中 ID3 是基础的决策树算法，C4.5 在它的基础上进行了改进，也是目前决策树中应用广泛的算法。然后在了解这些概念和原理后，强烈推荐你使用工具，具体工具的使用我会在后面进行介绍。




最后我们留一道思考题吧。请你用下面的例子来模拟下决策树的流程，假设好苹果的数据如下，请用 ID3 算法来给出好苹果的决策树。

编号	红	大	好苹果
1	是	是	是
2	是	否	是
3	否	是	否
4	否	否	否



如果你觉得这篇文章有所价值，欢迎点击“请朋友读”，把它分享给你的朋友或者同事。



# 数据分析实战 45 讲

即学即用的数据分析入门课

陈旻

清华大学计算机博士



新版升级：点击「👤请朋友读」，10位好友免费读，邀请订阅更有**现金**奖励。

© 版权归极客邦科技所有，未经许可不得转载

上一篇 16 | 数据分析基础篇答疑

下一篇 18 | 决策树（中）：CART，一棵是回归树，另一棵是分类树

## 精选留言 (34)

💬 写留言



JingZ

2019-01-21

👍 9

今天去面试一个金融分析师职位

问：算法知道吗？

我答：还在学习中，但我会python 爬虫，Numpy/Pandas~还有标准化(心想为嘛早上不认真看看今天的课程，起码说的出来C4.5是啥)😂😂...

展开 ∨



志



2019-01-22



「红」的信息增益为：1

「大」的信息增益为：0

因此选择「红」的作为根节点，「大」作为子节点。接着再通过计算得出「大」作为子节点效果更差，故进行剪枝。因此最终的完整决策树就只有「红」一个节点：

红（是）---好苹果（是）...

展开 ∨



你看起来很...

2019-01-21



老师在计算ID3父节点为天气时信息熵的时候，每一项的系数是3/6,这里是不是错了，不应该是4/7和3/7吗？



wonderland

2019-01-23



step1：将红作为属性来划分，有两个叶子节点D1，D2，分别对应是和否。用+代表是好苹果，-代表不是好苹果。

故  $D1 = \{\text{红}=\text{是}\}=\{1+, 2+\}$ ， $D2=\{\text{红}=\text{否}\}=\{3-, 4-\}$ ;

先分别计算2个叶子节点的信息熵：

$Ent(D1) = 0$ ， $Ent(D2) = 0$ ，作为子节点的归一化信息熵为： $1/2*0+1/2*0=0...$

展开 ∨



小熊猫

2019-02-14



决策树学习通常包括三个步骤：

1. 特征选择。选取最优特征来划分特征空间，用信息增益或者信息增益比来选择
2. 决策树的生成。ID3、C4.5、CART
3. 剪枝

...

展开 ∨



rainman

2019-02-14



在ID3算法那个例子中，当用“温度”作为根节点的时候，在温度为高的情况下，我计算的天气、湿度的信息增益都是1，而刮风为0.3115，所以这个子节点应该从天气或者湿度中选一个，我不明白为什么课程上写的结果是0、0、0.0615。望解答，谢谢。

展开 ∨



李龍

2019-01-22

👍 2

算法一点听不懂咋整

展开 ∨



sunny

2019-01-22

👍 2

红的信息增益为：1

大的信息增益为：0

红比大更纯，红放决策树上面作为父节点，大放下面作为子节点

展开 ∨



ken

2019-01-21

👍 2

苹果-大的信息熵：5/3

苹果-红的信息熵：1

归一化的信息熵：1

苹果-大信息增益更大，作为根节点，红作为子节点。

...

展开 ∨



陈志豪

2019-01-29

👍 1

请教，ID3算法计算非根节点时，是在“属性=属性值”的基础上进行计算呢，还是用的其他方式。例子中，我们选好“温度”作为根节点，计算下属节点的时候，下面的节点是在“温度=高”或其他的基础上再进行计算的吗？

展开 ∨



veical

2019-01-24

👍 1

老师，C4.5的例子，属性熵是多少？如何计算的？

展开 ∨



**Destroy、**

2019-01-21

👍 1

老师看完有两个疑问：

- 1、D：5个打篮球，5个不打篮球。为什么计算 $\text{ent}(D)$ 概率是 $3/6$ 呢？不应该是 $5/10$ 吗？
- 2、在介绍C4.5算法那部分，在计算 $\text{ent}(D1')$ 的时候，两个概率都是 $3/6$ ，不是 $1/3$ 和 $2/3$ 吗？难道我对信息熵的理解有误？



**开心**

2019-01-21

👍 1

这节课对数学知识有点涉及，要听明白了需要自己亲自算一下，验证结果，才有真正的理解，我一早先烧脑10分钟听完，慢慢消化。



**周飞**

2019-03-02

👍

1.根节点的信息熵是  $-(1/2 * \log(1/2) + 1/2 * \log(1/2)) = 1$

2.假如以红来作为根结点，那么有两个叶子 红和不红，

红的信息熵是  $-(1 * \log(1)) = 0$

不红的信息熵是  $-(1 * \log(1)) = 0$

所以 以红作为根节点的信息增益是  $1 - 0 = 1...$

展开 ▾



**王彬成**

2019-02-16

👍

1、计算案例中的下一个节点的信息增益有疑惑：

算得 $\text{Gain}(D, \text{天气})=1$ ，与文章提到的 $\text{Gain}(D, \text{天气})=0$ 矛盾，不知道哪里理解有误。

2、作业

苹果训练集中有4条数据，2个是好苹果，2个不是好苹果。

根节点的信息熵是：1...

展开 ▾



**柚子**

2019-02-14

👍

想问下ID3算法中以“温度”作为根节点后分为“高”、“中”、“低”，以“高”进行往下划分的时候是怎么计算的呢？此时 温度 = 高 这个节点的信息熵是为1吗？



月亮上的熊...

2019-02-13



$\text{Ent}(D) = 1$

颜色作为划分属性：

$D1(\text{颜色}=\text{红})=\{1+, 2+\}$

$D2(\text{颜色}=\text{不红})=\{3-, 4-\}$ ...

展开 ∨



圆圆的大食...

2019-02-01



红作为根节点，大作为子节点

展开 ∨



李沛欣

2019-01-31



今天的看完了。

决策树构造分为根节点，内部节点和叶节点。

对于冗余分枝需要进行剪枝处理，不然可能造成过拟合。分为预剪枝和后剪枝。...

展开 ∨



RayBan

2019-01-27



"金融分析师"最近好像很火哦,有没有从事或想从事该职业的小伙伴,感兴趣的互相探讨下.

展开 ∨